Machine Learning 101

Métricas

Felipe Alonso Atienza
Data Scientist @BBVA

Índice

Teoría de la decisión

- Regresión logística: P > 0.5 = ɣ

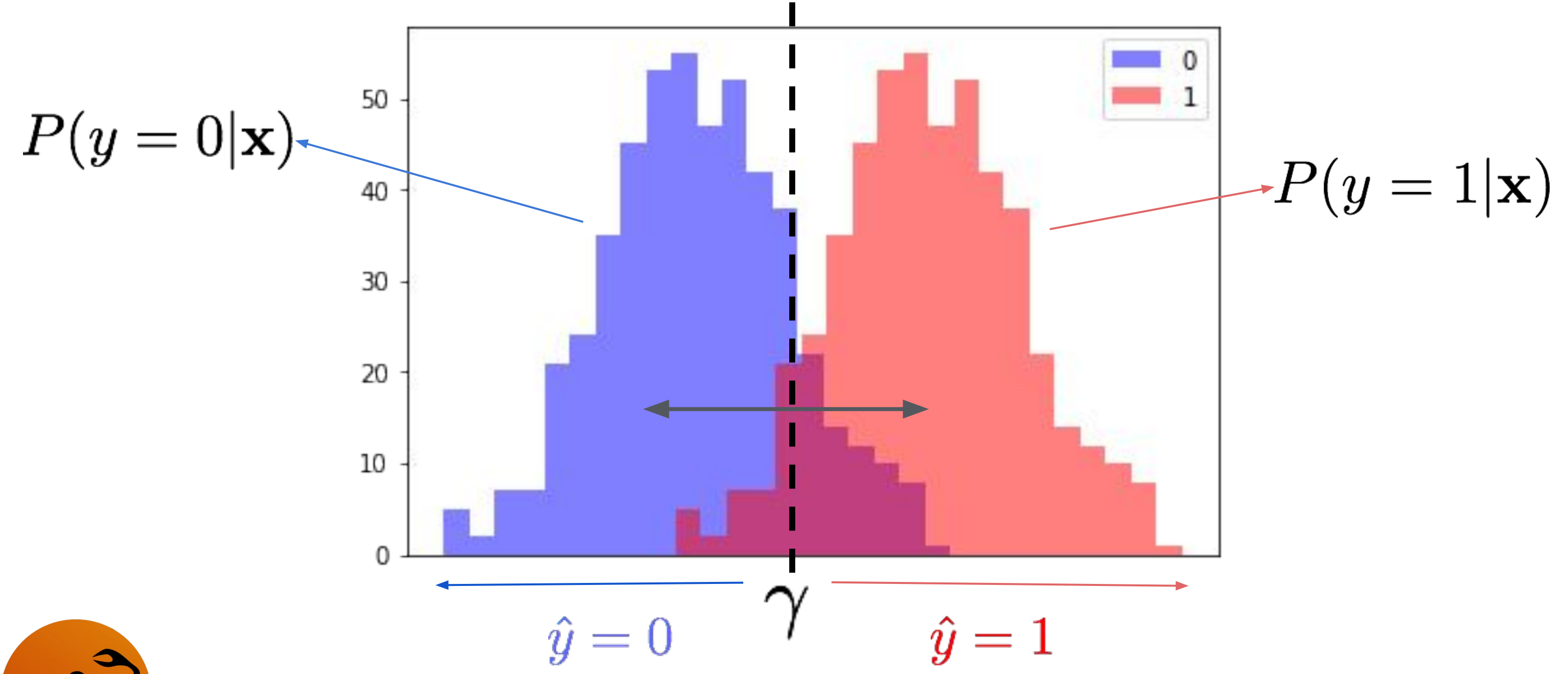

Métrica 1: tasa de error

- Contar errores:

  True: [1 1 0 0 0 0 0 0 0 0 0 0 0 0 0 1 1 0 0 0]
  Pred: [1 0 0 0 0 0 0 1 0 0 1 0 0 0 0 1 1 0 0 1]

  - **Tasa de error** (ERR): # errores / N
  - **Tasa de acierto** (ACC): # aciertos / N
    - ACC = 1 - ERR

- Da igual el sentido del error

Otras tasas de interés

- Si cuento el sentido de los errores, en un problema de clasificación binaria tengo cuatro posibilidades:
  - True Positive (TP)
  - True Negative (TN)
  - False Positive (FP)
  - False Negative (FN)

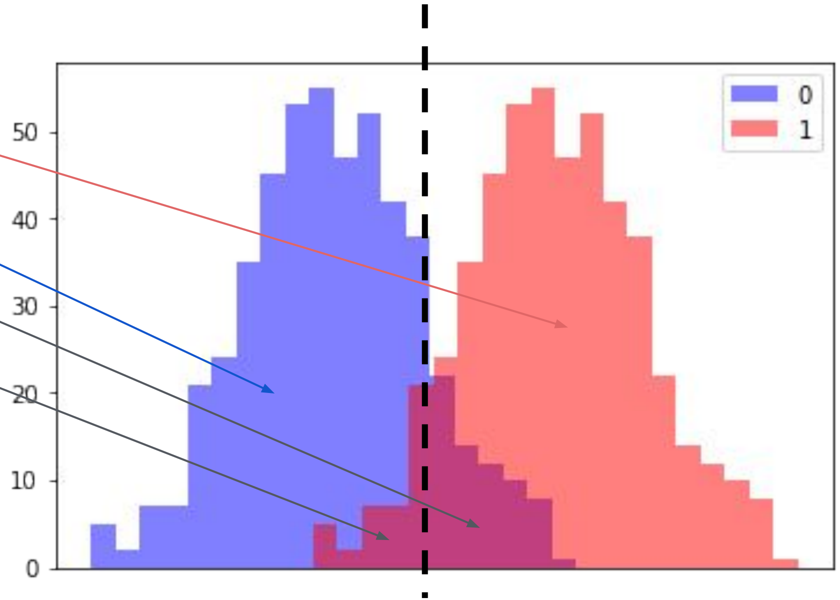

Matriz de confusión

- Representamos estas tasas en modo de **matriz de confusión**

		Etiquetas predichas	
		y_pred = 0	y_pred = 1
Etiquetas reales	y_true = 0	**TN**	**FP**
	y_true = 1	**FN**	**TP**

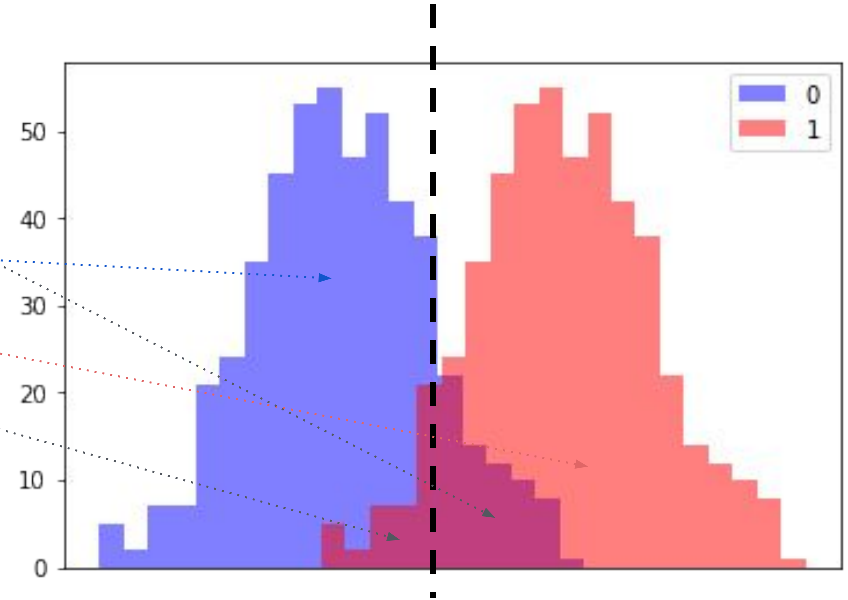

Métricas en clasificación

- Sobre la matriz de confusión se definen la siguientes métricas

		Etiquetas predichas	
		y_pred = 0	y_pred = 1
Etiquetas reales	y_true = 0	**TN**	**FP**
	y_true = 1	**FN**	**TP**

$$\text{ACC} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{SEN} = \text{Recall} = \frac{TP}{TP + FN}$$

$$\text{PPV} = \text{Precisión} = \frac{TP}{TP + FP}$$

$$\text{ESP} = \frac{TN}{TN + FP}$$

$$\text{FSC} = \text{F1-score} = \frac{2 \cdot \text{PPV} \cdot \text{SEN}}{\text{PPV} + \text{SEN}}$$

Compromiso entre métricas (I)

- Hay un compromiso entre las métricas (no se puede tener todo)

		Etiquetas predichas	
		y_pred = 0	y_pred = 1
Etiquetas reales	y_true = 0	**TN**	**FP**
	y_true = 1	**FN**	**TP**

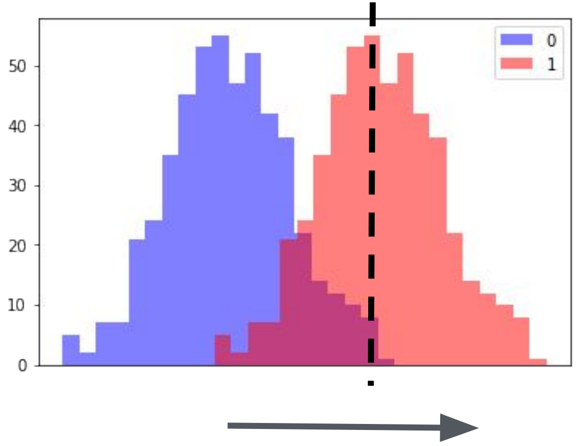

  - Si umbral ⇒, entonces TP↓, TN↑, FP↓, FN↑
    - SEN↓, ESP↑, PP↑

Compromiso entre métricas (II)

- Hay un compromiso entre las métricas (no se puede tener todo)

		Etiquetas predichas	
		y_pred = 0	y_pred = 1
Etiquetas reales	y_true = 0	**TN**	**FP**
	y_true = 1	**FN**	**TP**

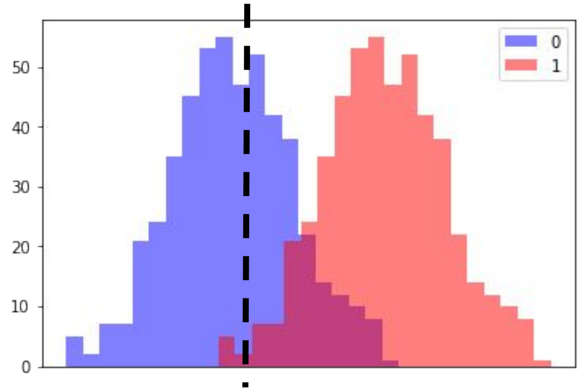

  - Si umbral ⇐, entonces TP↑, TN↓, FP↑, FN↓
    - SEN↑, ESP↓, PP↓

Curva ROC

- Representa la SEN vs 1-ESP (Tasa de Falsos Positivos) cuando desplazo el umbral

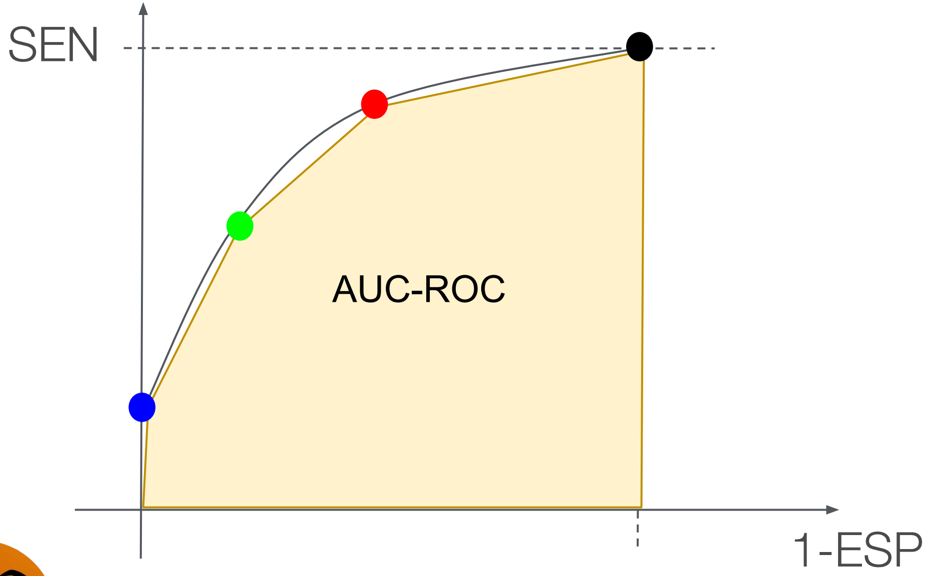

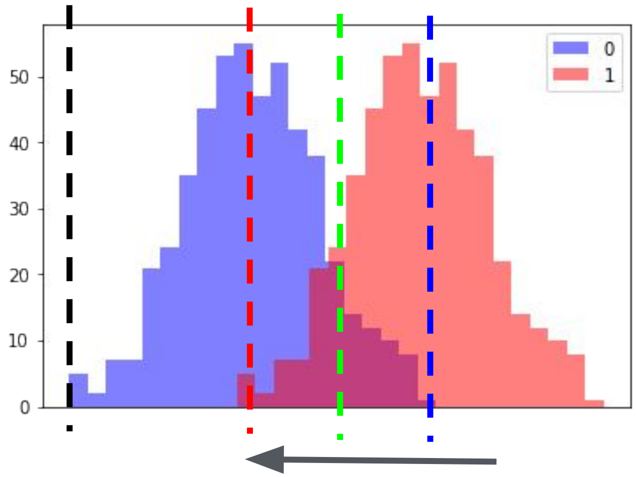

Curva ROC: situación ideal

- Representa la SEN vs 1-ESP (Tasa de Falsos Positivos) cuando desplazo el umbral

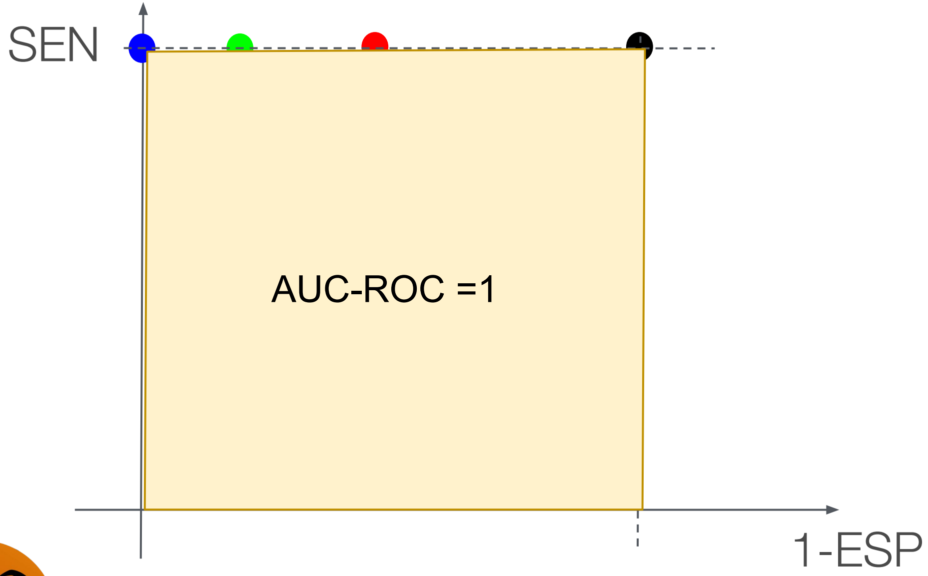

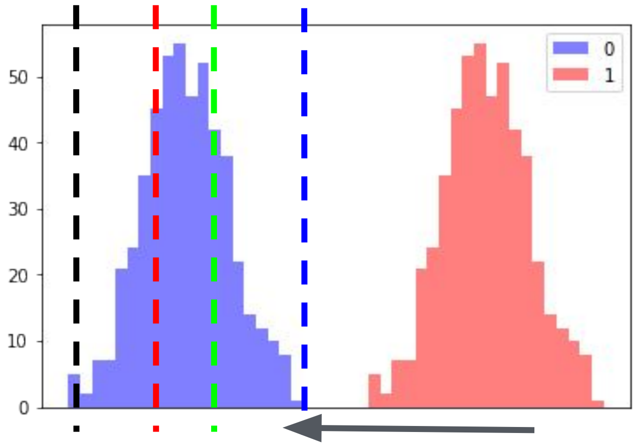

Curva ROC: peor caso

- Representa la SEN vs 1-ESP (Tasa de Falsos Positivos) cuando desplazo el umbral

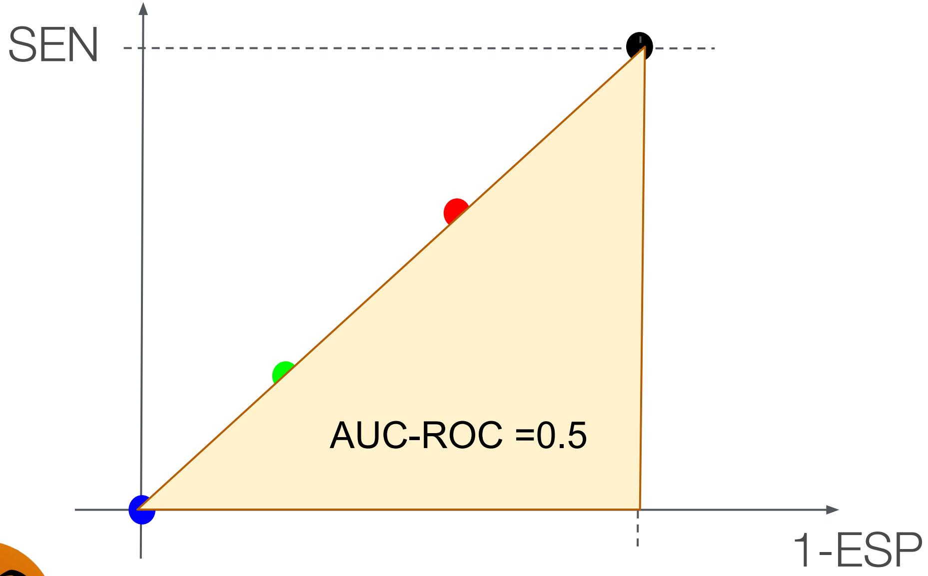

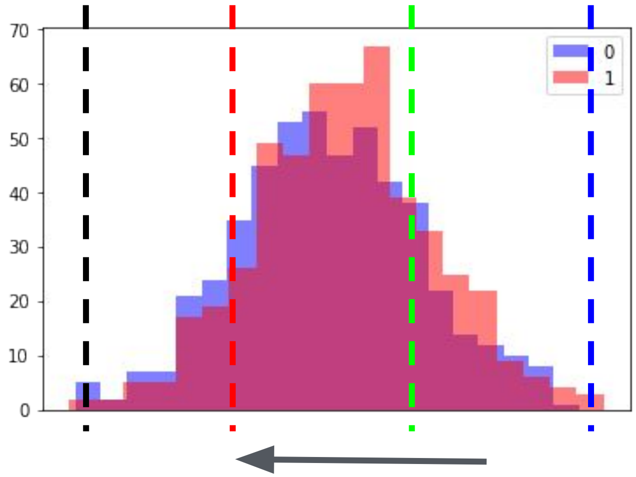

Curva ROC: utilidad

- Es un método interesante para comparar clasificadores

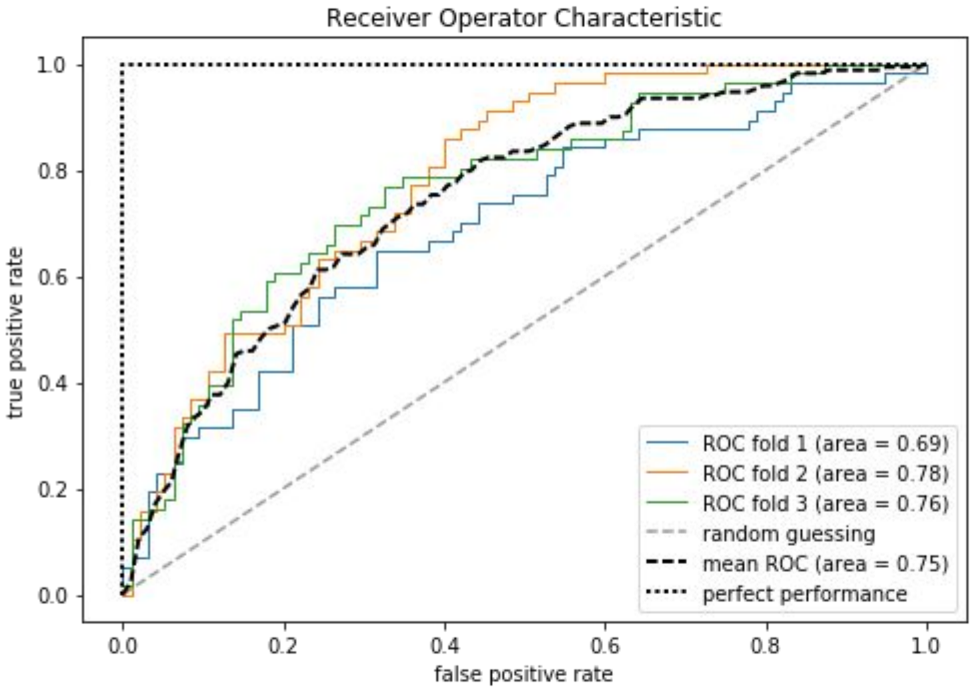

Clasificación multiclase

- Podemos calcular la matriz de confusión igualmente
  - Análisis de errores

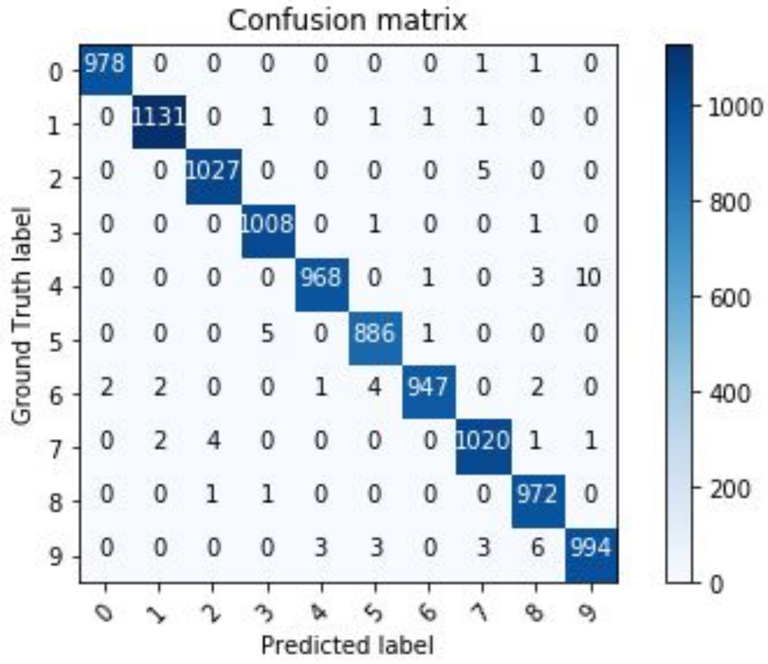

Métricas en sklearn

- Podéis consultar la documentación.

Índice

1. Métricas en clasificación
    a. **Problemas desbalanceados**
2. Métricas en regresión

Problemas desbalanceados

- ¿Qué pasa si la proporción de muestras y =1/0 es 90/10% y nuestro clasificador tiene una ACC = 0.9?
    - Decimos que estamos ante un problema desbalanceado cuando la proporción de una clase es mucho mayor que la proporción de la otra
        - Fraude: 0.1 %
            - Detección de anomalías
        - Fuga: 5-15%
- ¿Cómo entrenamos un clasificador en estas condiciones?
    - La ACC no nos sirve como métrica

Estrategias

- Utilizar métricas que ponderen la clases
  - FSC
  - Balanced Error Rate = 1-0.5(SEN + ESP)

- Penalizar más los errores en la clase minoritaria: class_weight

- Modificar el conjunto de entrenamiento para balancearlo
  - Sobremuestrear clase minoritaria
  - Crear muestras sintéticas de la clase minoritaria: SMOTE
  - Bajomuestrear clase mayoritaria

Índice

Regresión

- Mean Squared Error

$$\text{MSE}(y, \hat{y}) = \frac{1}{n_\text{samples}} \sum_{i=0}^{n_\text{samples}-1} (y_i - \hat{y}_i)^2.$$

- Mean Absolute Value

$$\text{MAE}(y, \hat{y}) = \frac{1}{n_\text{samples}} \sum_{i=0}^{n_\text{samples}-1} \left| y_i - \hat{y}_i \right|.$$

- Root Mean Squared Error

$$\text{RMSE}(y, \hat{y}) = \sqrt{\text{MSE}(y, \hat{y})}$$

- R^2

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=0}^{n_\text{samples}-1} (y_i - \hat{y}_i)^2}{\sum_{i=0}^{n_\text{samples}-1} (y_i - \bar{y})^2}$$

Referencias

- Introduction to Statistical Learning.
  - Capítulo 4, Sección 4.4.3

- Documentación scikit-learn

Hora de practicar